

# lavaanパッケージの紹介： 構造方程式モデリングや媒介分析

高知工科大学 経済・マネジメント学群  
日道俊之


# 本日のメニュー

- **lavaanパッケージ**(最新version: 0.6-5; Rosseel, 2012)を用いて
  1. 媒介分析
  2. 構造方程式モデリング
  3. (時間があれば)確証的因子分析
- **lavaanパッケージ**: 様々な多変量統計モデルに対応
  - パス解析・確証的因子分析・構造方程式モデリング・成長曲線モデル
  - くわしくはこちら(<http://lavaan.ugent.be/>)

# 媒介分析


# 単回帰

- 変数Xにより変数Yを説明するのが単回帰
  - 変数Xと変数Yの関係性が不明瞭な場合も多い




# 媒介分析

- 媒介分析により，変数 $X$ と変数 $Y$ の間を変数 $M$ が媒介するか否か検定可能
  - 媒介分析の数学的背景などに関しては村山(2009)が詳しい




# 媒介分析

- 媒介分析は複数のステップで行う(清水, 2014)
  1.  $X \rightarrow Y$ の総合効果が有意か否か(単回帰分析)
    - $Y = \mathbf{c'} * X + \text{切片} + \text{誤差}$
  2. 1に変数Mを加えた重回帰分析
    - $Y = \mathbf{b} * M + \mathbf{c} * X + \text{切片} + \text{誤差}$
  3. 間接効果 $\mathbf{a} * \mathbf{b}$ が有意か否か検定(後述)
  4. 直接効果 $\mathbf{c}$ が非有意か否かチェック
    - 有意だと部分媒介, 非有意だと完全媒介




# 媒介分析

- 媒介分析は複数のステップで行う(清水, 2014)
  1.  $X \rightarrow Y$ の総合効果が有意か否か(単回帰分析)
    - $Y = \mathbf{c}' * X + \text{切片} + \text{誤差}$
  2. 1に変数Mを加えた重回帰分析
    - $Y = \mathbf{b} * M + \mathbf{c} * X + \text{切片} + \text{誤差}$
  3. 間接効果 $\mathbf{a} * \mathbf{b}$ が有意か否か検定(後述)
  4. 直接効果 $\mathbf{c}$ が非有意か否かチェック
    - 有意だと部分媒介, 非有意だと完全媒介



# 媒介分析


- 媒介分析は複数のステップで行う(清水, 2014)
  1.  $X \rightarrow Y$ の総合効果が有意か否か(単回帰分析)
    - $Y = \mathbf{c}' * X + \text{切片} + \text{誤差}$
  2. 1に変数Mを加えた重回帰分析
    - $Y = \mathbf{b} * M + \mathbf{c} * X + \text{切片} + \text{誤差}$
  - 3. 間接効果 $\mathbf{a} * \mathbf{b}$ が有意か否か検定(後述)**
  4. 直接効果 $\mathbf{c}$ が非有意か否かチェック
    - 有意だと部分媒介, 非有意だと完全媒介





# 媒介分析

- 媒介分析は複数のステップで行う(清水, 2014)
  1.  $X \rightarrow Y$ の総合効果が有意か否か(単回帰分析)
    - $Y = \mathbf{c}' * X + \text{切片} + \text{誤差}$
  2. 1に変数Mを加えた重回帰分析
    - $Y = \mathbf{b} * M + \mathbf{c} * X + \text{切片} + \text{誤差}$
  3. 間接効果 $\mathbf{a} * \mathbf{b}$ が有意か否か検定(後述)
  4. 直接効果 $\mathbf{c}$ が非有意か否かチェック
    - 有意だと部分媒介, 非有意だと完全媒介




# 媒介分析

- 間接効果を推定する方法として、**ブートストラップ法**を用いて信頼区間を推定する方法がある
  - ブートストラップ法: 現状得られているデータセットから新しいデータセットを復元抽出し、推定を繰り返す

# 分析してみる

- マインドフルネス特性のうちActing and Awarenessという特性と、共感のEmpathic concernという特性のポジティブな関係を、アレキシサイミア特性が媒介する？ (Himichi et al., in prep.のデータセットの一部を使用)



# 分析してみる

```
### path c' ###  
res_lm <- lm(IRI_EC ~ FFMQ_AW, data=dat)  
summary(res_lm)  
### path c, path b ###  
res_lm2 <- lm(IRI_EC ~ FFMQ_AW + TAS_All, data=dat)  
summary(res_lm2)
```

## 単回帰

```
Call:  
lm(formula = IRI_EC ~ FFMQ_AW, data = dat)  
  
Residuals:  
    Min       1Q   Median       3Q      Max   
-1.99214 -0.39044 -0.02907  0.41463  1.60288  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)      
(Intercept)  2.92137    0.13164   22.192 < 2e-16 ***  
FFMQ_AW      0.12105    0.03885    3.116  0.00193 **  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.5862 on 514 degrees of freedom  
Multiple R-squared:  0.01854,    Adjusted R-squared:  0.01663  
F-statistic: 9.711 on 1 and 514 DF,  p-value: 0.001934
```

## 重回帰

```
Call:  
lm(formula = IRI_EC ~ FFMQ_AW + TAS_All, data = dat)  
  
Residuals:  
    Min       1Q   Median       3Q      Max   
-1.83743 -0.37188 -0.05062  0.39341  1.53961  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)      
(Intercept)  4.328190    0.272860   15.862 < 2e-16 ***  
FFMQ_AW      0.002126    0.042820    0.050    0.96  
TAS_All     -0.363036    0.062238   -5.833 9.65e-09 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.5682 on 513 degrees of freedom  
Multiple R-squared:  0.07959,    Adjusted R-squared:  0.076  
F-statistic: 22.18 on 2 and 513 DF,  p-value: 5.774e-10
```

# 分析してみる

### lavaanパッケージによる間接効果の推定

```
library(lavaan)
```

```
model1 <- '
```

```
    IRI_EC ~ c*FFMQ_AW  ### path c ###
```

```
    TAS_All ~ a*FFMQ_AW  ### path a ###
```

```
    IRI_EC ~ b*TAS_All    ### path b ###
```

```
    Ind := a*b            ### indirect effects ###
```

```
    Total := c+(a*b)      ### total effects ###
```

```
;
```

```
fit1 <- sem(model1, data=dat, bootstrap=2000, se="bootstrap")
```

```
parameterEstimates(fit1, ci=T, level=0.95, boot.ci.type="bca.simple")
```


1. モデルを記述するパート(**赤枠**)
2. 推定方法やパラメータを設定する箇所(**青枠**)に分かれる

# 分析してみる


- 基本的なモデルの書き方

タイプ	オペレーター	例
回帰	$\sim$	$Y \sim X$
(残差)(共)共分散	$\sim\sim$	$Y \sim\sim X$
切片	$\sim 1$	$X \sim 1$
新しいパラメータの定義	$:=$	$\text{indirect} := a*b$
潜在変数の定義	$=\sim$	$X =\sim a1 + a2$

※相関を0にしたいときは  $Y \sim\sim 0*X$  のようにする



回帰



相関

# 分析してみる

```
fit1 <- sem(model1, data=dat, bootstrap=2000, se="bootstrap")  
parameterEstimates(fit1, ci=T, level=0.95, boot.ci.type="bca.simple")
```

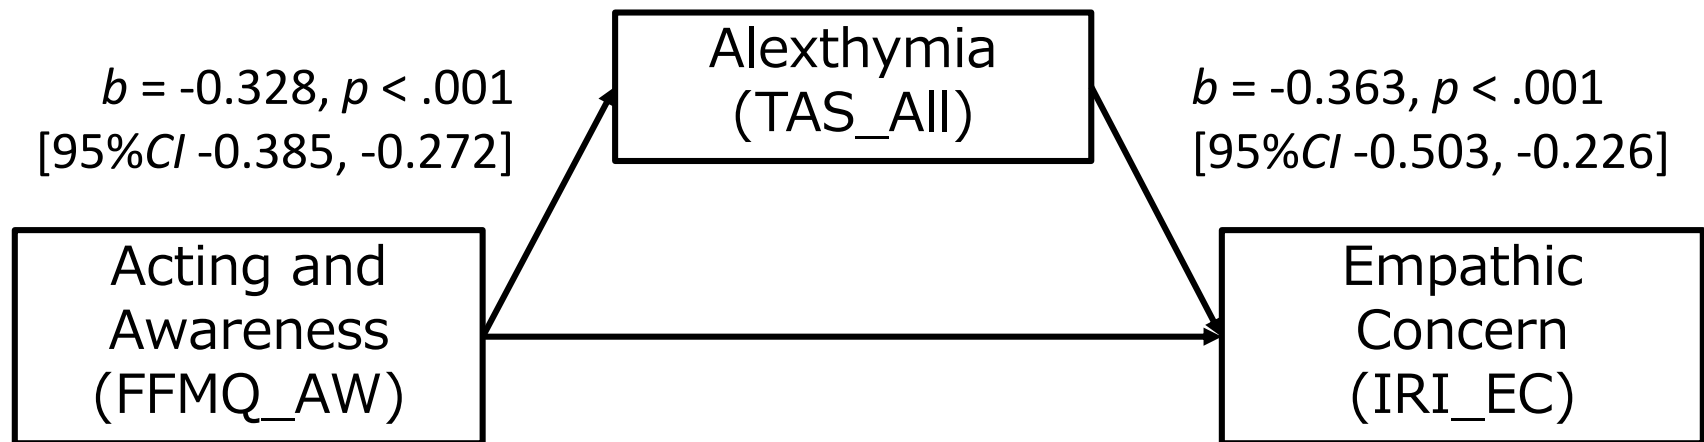
1. Bootstrap: リサンプリング数
2. se: 標準誤差の推定方法
3. Ci: 信頼区間の出力(T or F)
4. level: 信頼区間の幅の設定(0.95?0.99?)
5. Boot.ci.type: 信頼区間の設定方法("norm", "basic", "perc", "bca.simple")
  - パーセンタイル法("perc"): ブートストラップ標本から得られた間接効果の分布をそのまま使用
  - **バイアス修正法("bca.simple")**: 推定値のバイアスを求めてそれを除去したうえで間接効果を推定

(村山, 2009)

# 分析してみる

	lhs	op	rhs	label	est	se	z	pvalue	ci.lower	ci.upper
1	IRI_EC	~	FFMQ_AW	c	0.002	0.051	0.042	0.967	-0.100	0.101
2	TAS_All	~	FFMQ_AW	a	-0.328	0.028	-11.822	0.000	-0.385	-0.272
3	IRI_EC	~	TAS_All	b	-0.363	0.070	-5.188	0.000	-0.503	-0.226
4	IRI_EC	~~	IRI_EC		0.321	0.021	15.482	0.000	0.285	0.366
5	TAS_All	~~	TAS_All		0.182	0.011	14.457	0.000	0.140	0.185
6	FFMQ_AW	~~	FFMQ_AW		0.441	0.000	NA	NA	0.441	0.441
7	Ind	:=	a*b	Ind	0.119	0.028	4.548	0.000	0.071	0.172
8	Total	:=	c+(a*b)	Total	0.121	0.043	2.839	0.005	0.033	0.202

Indirect effects:  $b = 0.119, p < .001$  [95%CI 0.071, 0.172]

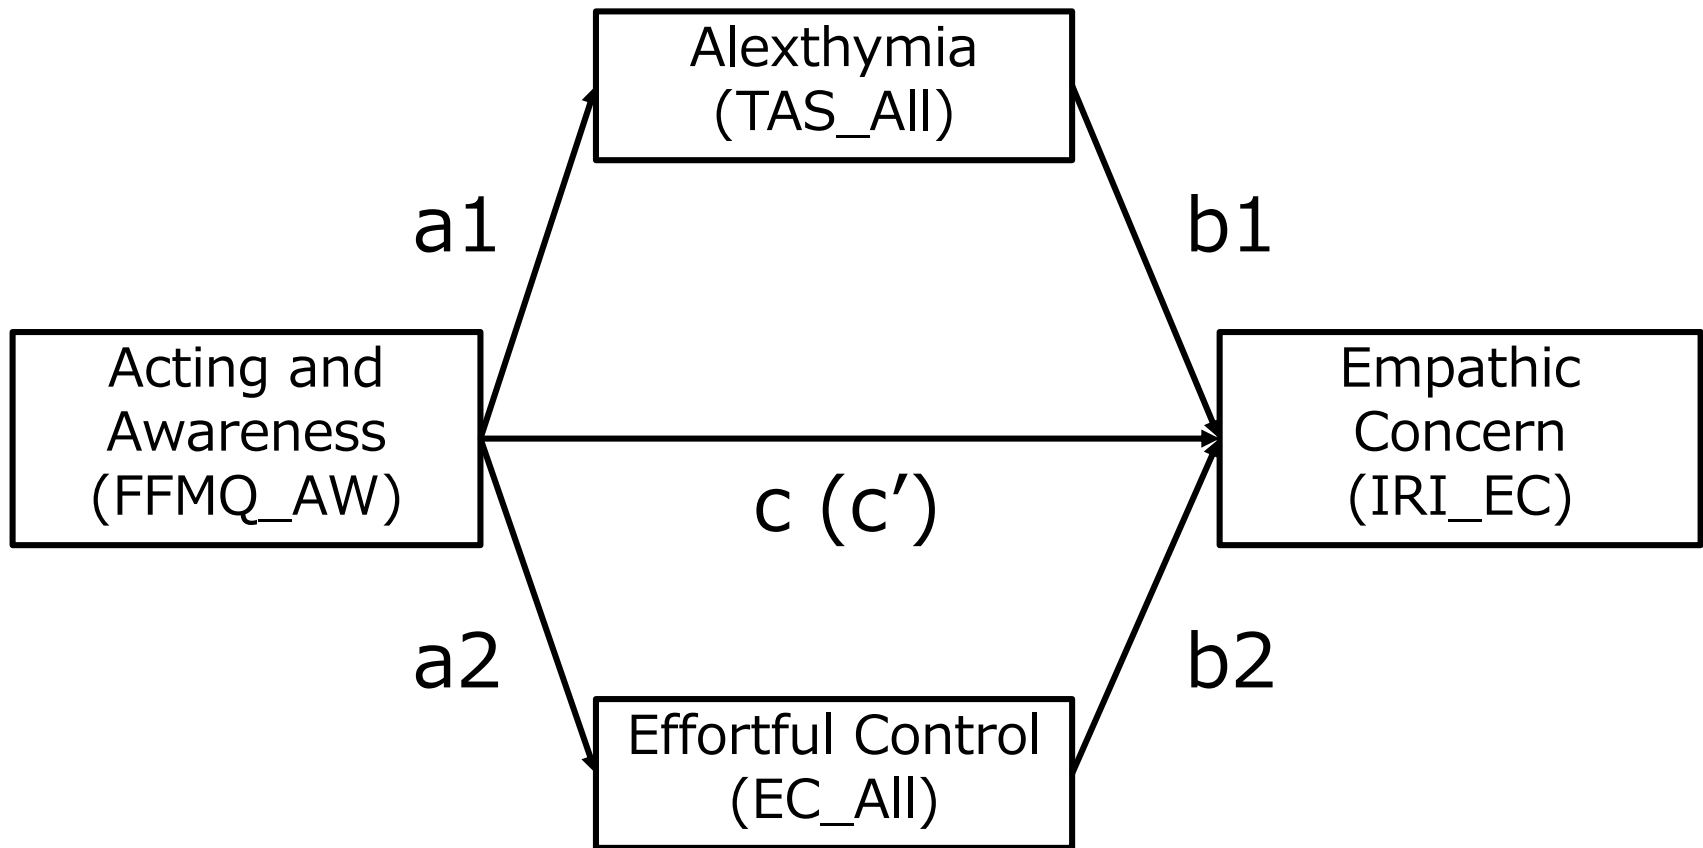


$b = 0.121, p = .005$  [95%CI 0.033, 0.202]



# 媒介変数は複数でもOK

- 媒介変数にエフォートフル・コントロールを追加  
(Himichi et al., in prep. のデータセットの一部を使用)



# pathを追加するだけ

### lavaanパッケージによる間接効果の推定

```
library(lavaan)
```

```
model2 <- model2 <- '
```

```
    IRI_EC ~ c*FFMQ_AW
```

```
    ### path c ###
```

```
    TAS_All ~ a1*FFMQ_AW
```

```
    ### path a1 ###
```

```
    EC_All ~ a2*FFMQ_AW
```

```
    ### path a2 ###
```

```
    IRI_EC ~ b1*TAS_All
```

```
    ### path b1 ###
```

```
    IRI_EC ~ b2*EC_All
```

```
    ### path b2 ###
```

```
    Ind1 := a1*b1
```

```
    ### indirect effects1 ###
```

```
    Ind2 := a2*b2
```

```
    ### indirect effects2 ###
```

```
    totalInd := (a1*b1)+(a2*b2)
```

```
    ### total indirect effects ###
```

```
    total := c+(a1*b1)+(a2*b2)
```

```
    ### total effects ###
```

```
    TAS_All ~~ EC_All
```

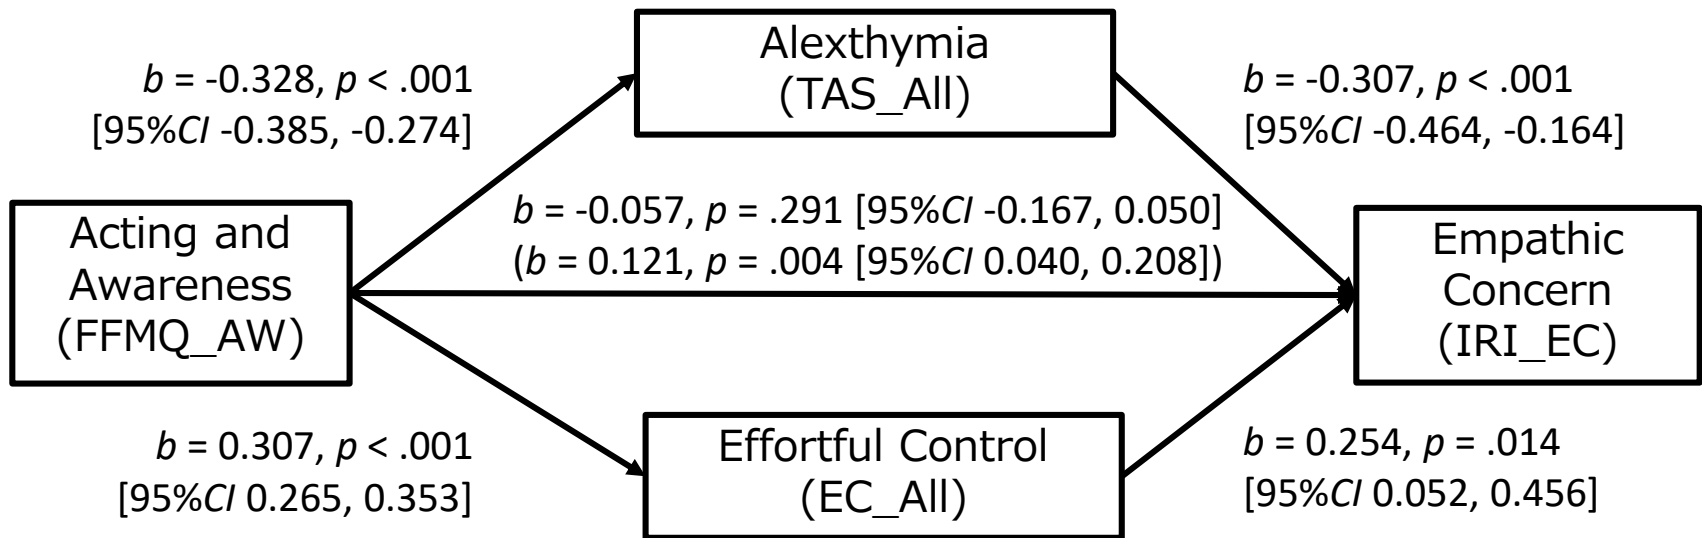
```
 '
```

```
fit2 <- sem(model2, data=dat, bootstrap=2000, se="bootstrap")
```

```
parameterEstimates(fit2, ci=T, level=0.95, boot.ci.type="bca.simple")
```

	lhs	op	rhs	label	est	se	z	pvalue	ci.lower	ci.upper
1	IRI_EC	~	FFMQ_AW	c	-0.057	0.054	-1.057	0.291	-0.167	0.050
2	TAS_All	~	FFMQ_AW	a1	-0.328	0.028	-11.512	0.000	-0.385	-0.274
3	EC_All	~	FFMQ_AW	a2	0.307	0.022	13.801	0.000	0.265	0.353
4	IRI_EC	~	TAS_All	b1	-0.307	0.077	-3.999	0.000	-0.464	-0.164
5	IRI_EC	~	EC_All	b2	0.254	0.103	2.452	0.014	0.052	0.456
6	TAS_All	~~	EC_All		-0.036	0.006	-5.855	0.000	-0.048	-0.024
7	IRI_EC	~~	IRI_EC		0.316	0.020	15.722	0.000	0.283	0.366
8	TAS_All	~~	TAS_All		0.162	0.011	14.092	0.000	0.141	0.186
9	EC_All	~~	EC_All		0.082	0.006	14.786	0.000	0.072	0.094
10	FFMQ_AW	~~	FFMQ_AW		0.441	0.000	NA	NA	0.441	0.441
11	Ind1	:=	a1*b1	Ind1	0.100	0.028	3.583	0.000	0.052	0.163
12	Ind2	:=	a2*b2	Ind2	0.078	0.032	2.470	0.014	0.018	0.140
13	Ind	:=	(a1*b1)+(a2*b2)	Ind	0.178	0.036	4.913	0.000	0.113	0.259
14	Total	:=	c+(a1*b1)+(a2*b2)	Total	0.121	0.042	2.850	0.004	0.040	0.208

Indirect effects1:  $b = 0.100$ ,  $p < .001$  [95%CI 0.052, 0.163]

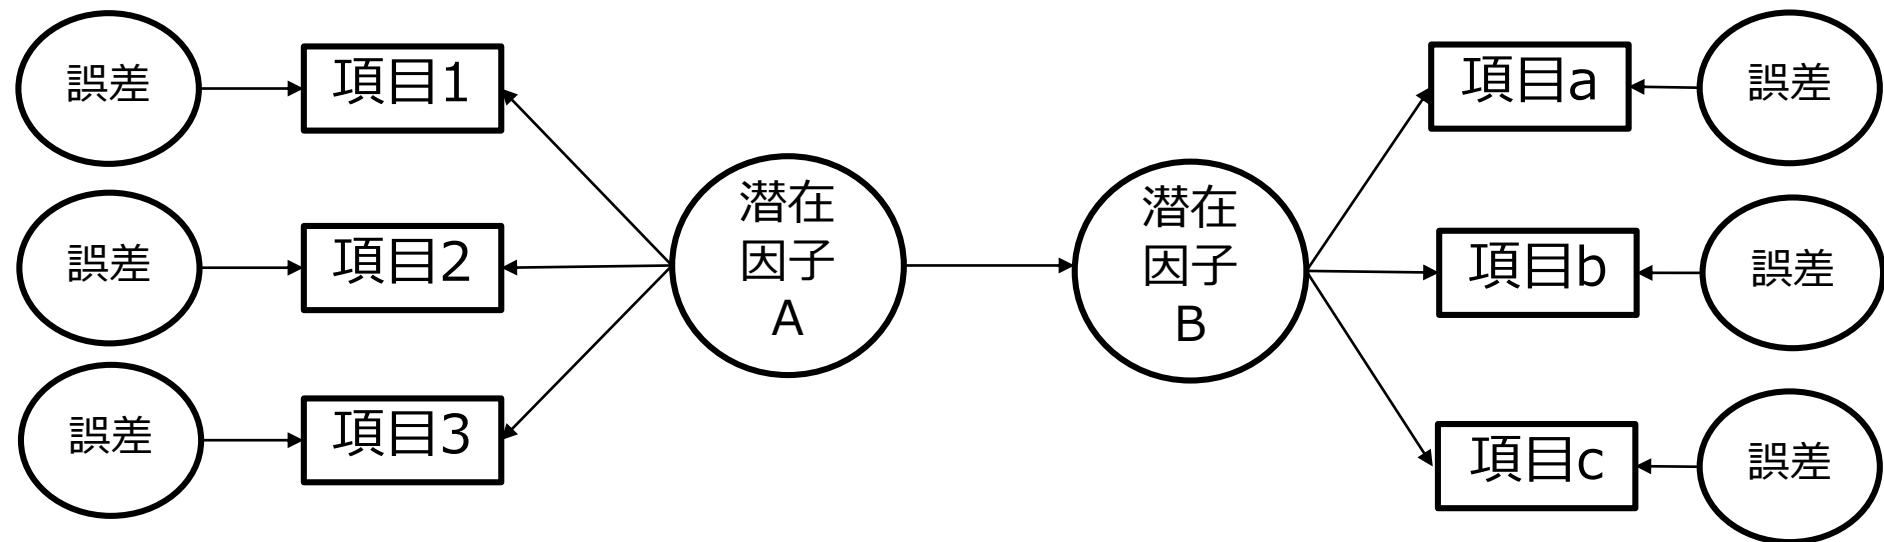


Indirect effects2:  $b = 0.078$ ,  $p = .014$  [95%CI 0.018, 0.140]

# 構造方程式モデリング

# 構造方程式モデリング

- 構造方程式モデリング(**因子分析** + **パス解析**)
  - 媒介分析も構造方程式モデリングのひとつ
- 潜在因子を抽出して，潜在因子間の相関・回帰を検討することが可能
  - 希薄化を抑制することが可能(狩野, 2002)



# 構造方程式モデリング

例. 2つの尺度の平均値をそれぞれ算出して、相関係数を算出した場合と、それぞれ潜在変数を抽出して因子間相関を算出(狩野, 2002)

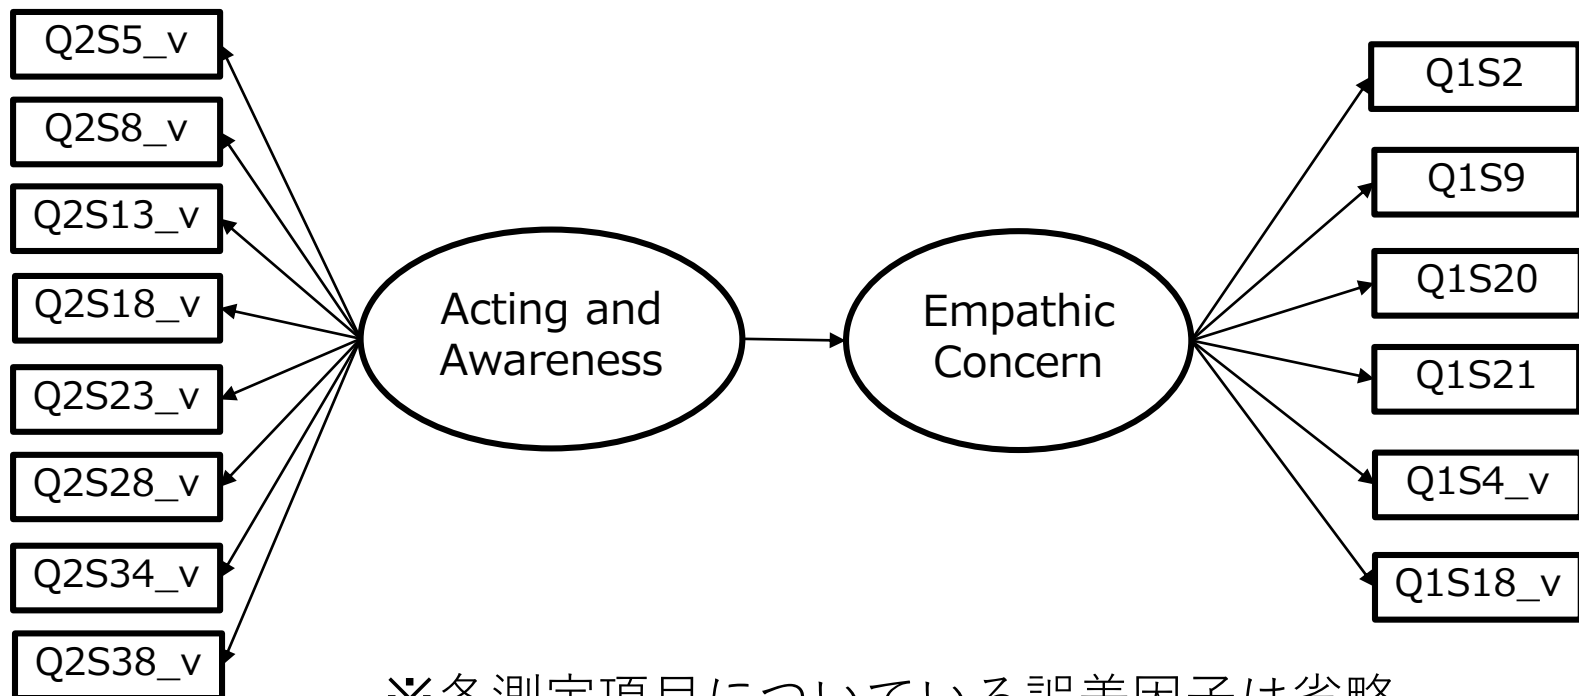
- たいてい後者の方が相関係数が高い
- 誤差が統制されていないことが問題
- 信頼性の低い尺度では希薄化が大きな問題

言語性尺度の 項目数	因子間相関		尺度の信頼性		
	検証的因子分析	尺度間相関	尺度名	$\alpha$ 係数	$\rho$ or $\rho'$
4	0.444	0.354	言語性尺度	0.764	0.766
			動作性尺度	0.661	0.668
6	0.495	0.405	言語性尺度	0.747	0.703
			動作性尺度	0.661	0.668

# 分析してみる

```
model3 <- '  
EC =~ Q1S2+Q1S9+Q1S20+Q1S22+Q1S4_v+Q1S14_v+Q1S18_v  
AW =~ Q2S5_v+Q2S8_v+Q2S13_v+Q2S18_v+Q2S23_v+Q2S28_v+Q2S34_v+Q2S38_v  
EC ~ AW  
'
```

```
fit3 <- sem(model3, data=dat, missing="ml", estimator="ML")  
summary(fit3, fit.measures=T)
```



※各測定項目についている誤差因子は省略

# 分析してみる

```
model3 <- '  
EC =~ Q1S2+Q1S9+Q1S20+Q1S22+Q1S4_v+Q1S14_v+Q1S18_v  
AW =~ Q2S5_v+Q2S8_v+Q2S13_v+Q2S18_v+Q2S23_v+Q2S28_v+Q2S34_v+Q2S38_v  
EC ~ AW  
'  
  
fit3 <- sem(model3, data=dat, missing="ml", estimator="ML")  
summary(fit3, fit.measures=T)
```

1. Missing: 欠損値の補完方法("ml"は最尤法)
  2. estimator: 推定方法[デフォルトが"ML"(最尤法)]
    - 最小二乗法(e.g. "GLS")や頑健最尤法(e.g. "MLM")なども使用可能
- ※sem関数内でse="bootstrap"とすると、標準誤差をブートストラップ法で推定してくれる



# 分析してみる

```
lavaan 0.6-5 ended normally after 35 iterations

Estimator              ML
Optimization method    NLMINB
Number of free parameters 46

Number of observations    516
Number of missing patterns 1

Model Test User Model:

Test statistic          523.113
Degrees of freedom      89
P-value (Chi-square)    0.000

Model Test Baseline Model:

Test statistic          2478.773
Degrees of freedom     105
P-value                 0.000

User Model versus Baseline Model:

Comparative Fit Index (CFI)    0.817
Tucker-Lewis Index (TLI)      0.784

Loglikelihood and Information Criteria:

Loglikelihood user model (H0)    -9490.983
Loglikelihood unrestricted model (H1) -9229.426

Akaike (AIC)                    19073.965
Bayesian (BIC)                  19269.286
Sample-size adjusted Bayesian (BIC) 19123.274

Root Mean Square Error of Approximation:

RMSEA                          0.097
90 Percent confidence interval - lower 0.089
90 Percent confidence interval - upper 0.105
P-value RMSEA <= 0.05          0.000

Standardized Root Mean Square Residual:

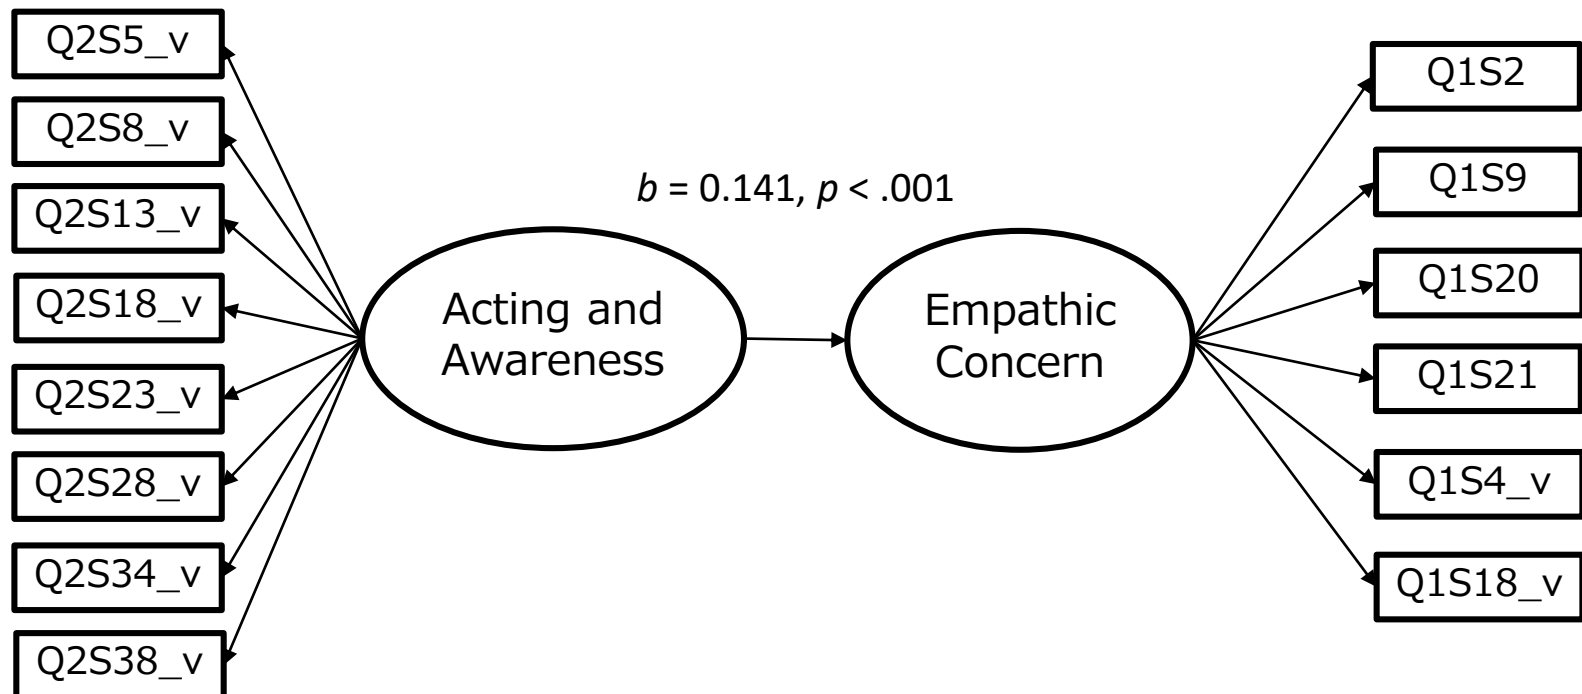
SRMR                           0.079

Parameter Estimates:

Information                     Observed
Observed information based on    Hessian
Standard errors                  Standard
```

- モデル適合度のだいたいの目安
  - CFI (GFI, AGFI)  $\geq .90$ や $\geq .95$
  - RMSEA  $\leq .05$
- 研究の目的やと照らし合わせて、モデルの適合度は扱われた方がよい(南風原, 2002)
  - とにかく適合するモデルを探したりはしない方がよい


Latent Variables:				
	Estimate	Std.Err	z-value	P(> z )
EC = ~				
Q1S2	1.000			
Q1S9	1.099	0.135	8.140	0.000
Q1S20	0.623	0.115	5.425	0.000
Q1S22	1.048	0.134	7.795	0.000
Q1S4_v	1.548	0.197	7.878	0.000
Q1S14_v	1.406	0.176	7.991	0.000
Q1S18_v	1.470	0.185	7.934	0.000
AW = ~				
Q2S5_v	1.000			
Q2S8_v	0.834	0.063	13.309	0.000
Q2S13_v	1.015	0.061	16.572	0.000
Q2S18_v	0.916	0.062	14.861	0.000
Q2S23_v	0.707	0.066	10.714	0.000
Q2S28_v	0.658	0.056	11.801	0.000
Q2S34_v	0.805	0.062	12.956	0.000
Q2S38_v	0.785	0.059	13.330	0.000
Regressions:				
	Estimate	Std.Err	z-value	P(> z )
EC ~				
AW	0.141	0.033	4.215	0.000




# 単回帰分析との比較

- 各項目の平均値により尺度化して単回帰分析を行った結果と比較
  - 潜在変数を抽出した方が回帰係数が高い
  - 希薄化が生じていた

$$b = \mathbf{0.121}, p = .005$$



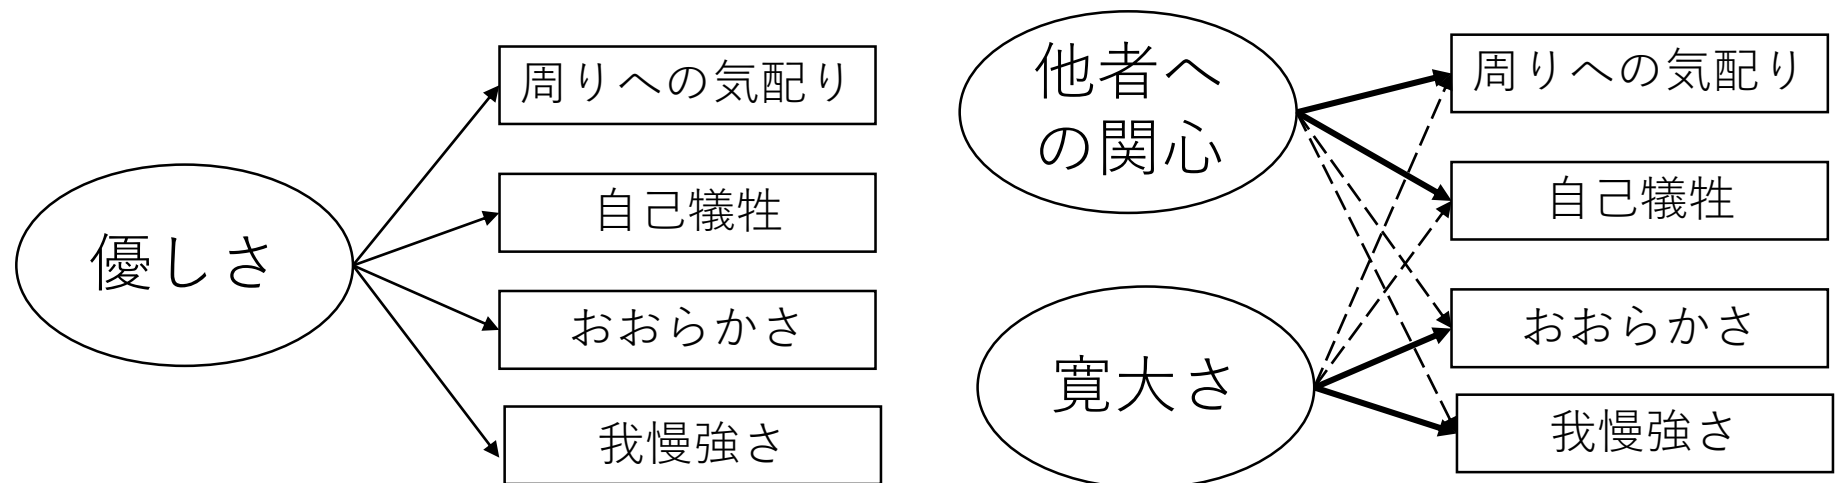
$$b = \mathbf{0.141}, p < .001$$



# 確証の因子分析

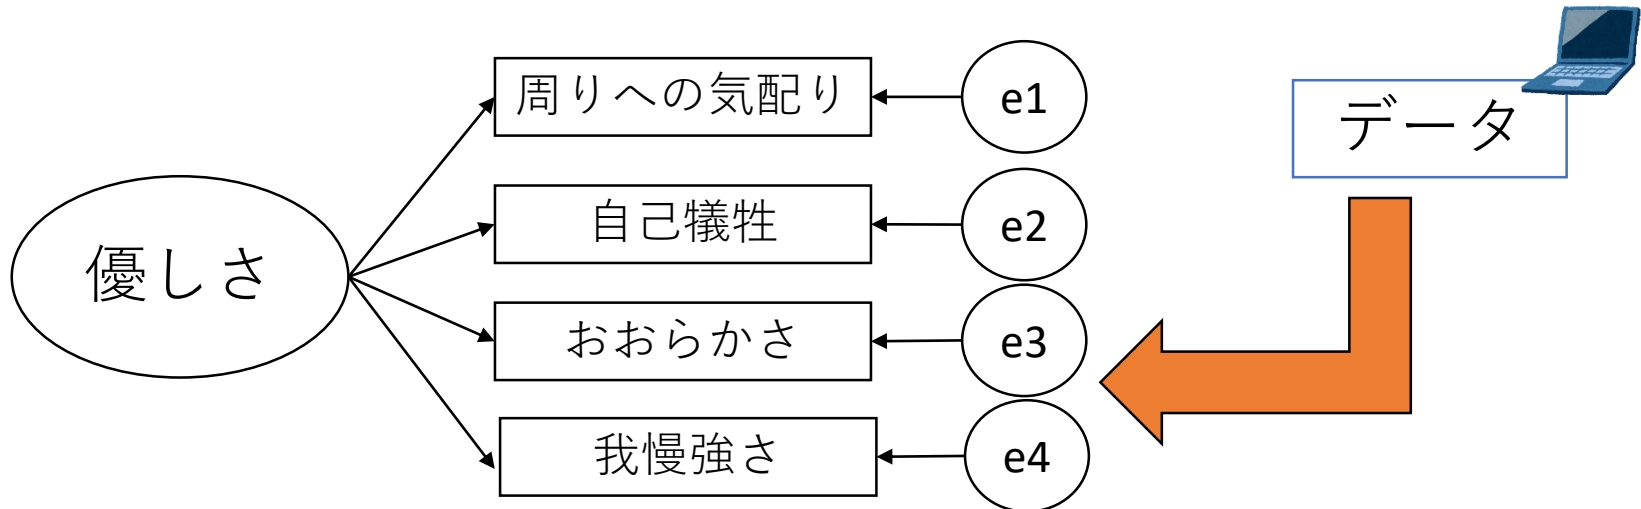
# 探索的因子分析

- 尺度を作成する際に使用される因子分析
  - 複数の項目群を1つの因子にまとめる
- よく使用されている方法が**探索的因子分析**(psychパッケージの**fa関数**で分析できる)
  - いくつかの因子数を想定し，その数に項目群をまとめる
  - 各項目がどの因子に含まれるか探索的に決定



# 確証的因子分析

- 探索的因子分析では，想定する因子数によりどの項目がどの因子にまとまるか変化するという問題
- 事前に因子モデルに対する仮説がある場合，その仮説が妥当かどうか検証したい
  - 構造方程式モデリングを用いた**確証的因子分析**



# 分析してみる

```
model <- '
```

```
  PD=~Q1S6+Q1S10+Q1S17+Q1S24+Q1S27+Q1S13_v+Q1S19_v
```

```
  EC=~Q1S2+Q1S9+Q1S20+Q1S22+Q1S4_v+Q1S14_v+Q1S18_v
```

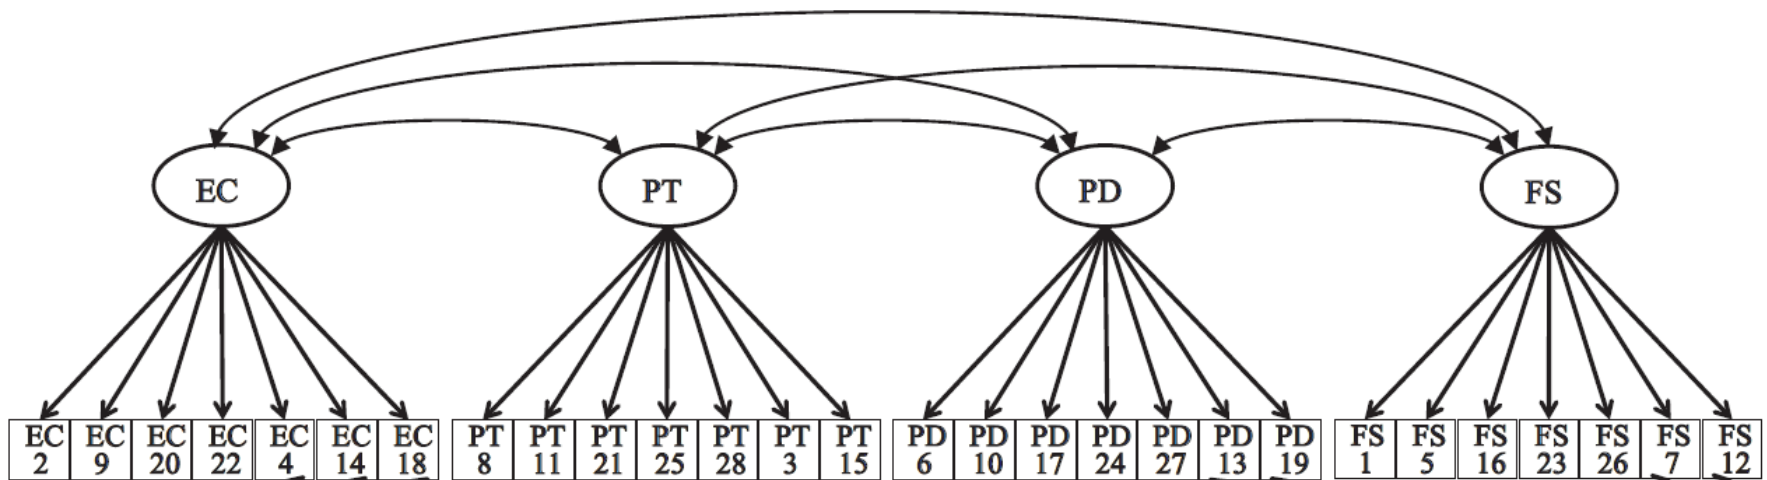
```
  PT=~Q1S8+Q1S11+Q1S21+Q1S25+Q1S28+Q1S3_v+Q1S15_v
```

```
  FS=~Q1S1+Q1S5+Q1S16+Q1S23+Q1S26+Q1S7_v+Q1S12_v
```

```
  '
```

```
result <- cfa(model, data=dat, orthogonal=F, std.lv=F, estimator="ML",  
missing="ml")
```

```
summary(result, fit.measures=T, standardized=T)
```



日道他 (2017) ※各測定項目についている誤差因子は省略

# 分析してみる

```
model <- '  
  PD=~Q1S6+Q1S10+Q1S17+Q1S24+Q1S27+Q1S13_v+Q1S19_v  
  EC=~Q1S2+Q1S9+Q1S20+Q1S22+Q1S4_v+Q1S14_v+Q1S18_v  
  PT=~Q1S8+Q1S11+Q1S21+Q1S25+Q1S28+Q1S3_v+Q1S15_v  
  FS=~Q1S1+Q1S5+Q1S16+Q1S23+Q1S26+Q1S7_v+Q1S12_v  
'
```

```
result <- cfa(model, data=dat, orthogonal=F, std.lv=F, estimator="ML",  
missing="ml")  
summary(result, fit.measures=T, standardized=T)
```

1. **orthogonal**: 因子間は直交(相関=0)しているか否か(デフォルトはFALSE)
2. **std.lv**: FALSEにすると、各因子の初めの観測変数の因子負荷量(係数)を1に固定するか否か(デフォルトはFALSE)
3. **standardized**: 標準化係数を出力するか否か



# 分析してみる

```
lavaan 0.6-5 ended normally after 38 iterations

Estimator                      ML
Optimization method             NLMINB
Number of free parameters       90

Number of observations          516
Number of missing patterns      1

Model Test User Model:

Test statistic                   1657.259
Degrees of freedom               344
P-value (Chi-square)            0.000

Model Test Baseline Model:

Test statistic                   4654.570
Degrees of freedom               378
P-value                         0.000

User Model versus Baseline Model:

Comparative Fit Index (CFI)     0.693
Tucker-Lewis Index (TLI)       0.663

Loglikelihood and Information Criteria:

Loglikelihood user model (H0)    -18441.665
Loglikelihood unrestricted model (H1) -17613.035

Akaike (AIC)                    37063.330
Bayesian (BIC)                  37445.480
Sample-size adjusted Bayesian (BIC) 37159.803

Root Mean Square Error of Approximation:

RMSEA                           0.086
90 Percent confidence interval - lower 0.082
90 Percent confidence interval - upper 0.090
P-value RMSEA <= 0.05           0.000

Standardized Root Mean Square Residual:

SRMR                            0.106

Parameter Estimates:

Information                      Observed
Observed information based on     Hessian
Standard errors                   Standard
```

- 適合度はCFI=.693, RMSEA=0.086なので低い

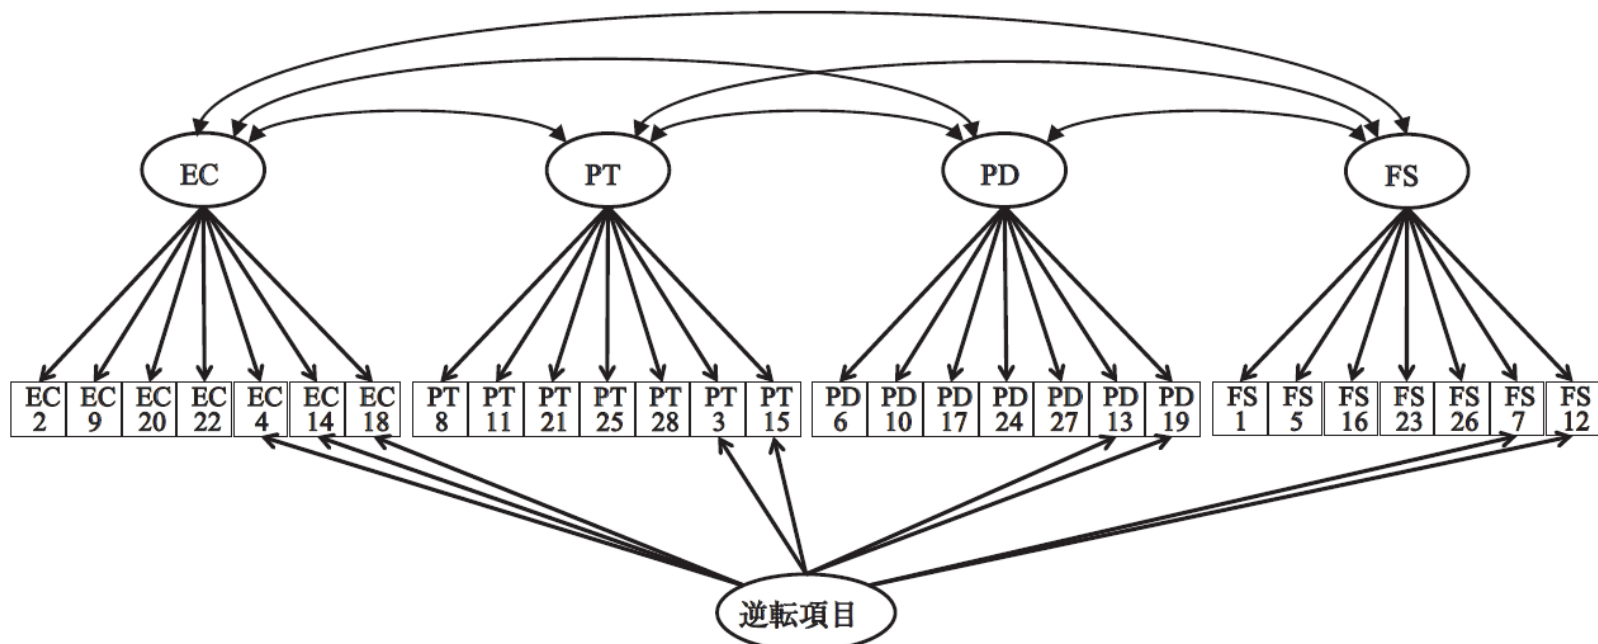
# 分析してみる

- 適合度はCFI=.693, RMSEA=0.086なので低い
- std.allに各観測変数, 潜在変数が標準化されたパラメータが出力
  - このパラメータが因子負荷量

Latent Variables:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
PD =~						
Q1S6	1.000				0.678	0.662
Q1S10	1.031	0.084	12.287	0.000	0.699	0.690
Q1S17	1.014	0.084	12.050	0.000	0.687	0.684
Q1S24	1.085	0.084	12.936	0.000	0.735	0.716
Q1S27	0.826	0.075	11.024	0.000	0.560	0.590
Q1S13_v	0.105	0.070	1.494	0.135	0.071	0.074
Q1S19_v	0.491	0.067	7.316	0.000	0.333	0.368
EC =~						
Q1S2	1.000				0.611	0.673
Q1S9	0.979	0.085	11.474	0.000	0.598	0.650
Q1S20	0.710	0.079	8.949	0.000	0.433	0.477
Q1S22	0.995	0.084	11.816	0.000	0.608	0.626
Q1S4_v	0.721	0.092	7.841	0.000	0.440	0.469
Q1S14_v	0.691	0.085	8.141	0.000	0.422	0.478
Q1S18_v	0.695	0.090	7.700	0.000	0.425	0.456
PT =~						
Q1S8	1.000				0.585	0.635
Q1S11	0.966	0.092	10.531	0.000	0.565	0.596
Q1S21	0.997	0.092	10.832	0.000	0.583	0.624
Q1S25	0.833	0.088	9.431	0.000	0.487	0.538
Q1S28	1.048	0.095	10.994	0.000	0.613	0.639
Q1S3_v	0.100	0.079	1.263	0.207	0.059	0.064
Q1S15_v	0.225	0.078	2.868	0.004	0.131	0.147
FS =~						
Q1S1	1.000				0.539	0.521
Q1S5	1.480	0.135	10.966	0.000	0.798	0.761
Q1S16	1.317	0.129	10.218	0.000	0.710	0.692
Q1S23	1.294	0.123	10.486	0.000	0.697	0.728
Q1S26	1.330	0.125	10.644	0.000	0.717	0.681
Q1S7_v	0.576	0.096	5.971	0.000	0.311	0.319
Q1S12_v	0.812	0.107	7.591	0.000	0.438	0.427
Covariances:						
	Estimate	Std.Err	z-value	P(> z )	Std.lv	Std.all
PD ~~						
EC	0.012	0.024	0.485	0.628	0.028	0.028
PT	0.020	0.023	0.877	0.381	0.051	0.051
FS	0.113	0.023	4.810	0.000	0.308	0.308
EC ~~						
PT	0.222	0.030	7.278	0.000	0.622	0.622
FS	0.129	0.023	5.560	0.000	0.393	0.393
PT ~~						
FS	0.142	0.023	6.088	0.000	0.449	0.449

# 逆転項目

- 心理尺度には逆転項目が含まれている
  - 想定されていたようなメリットはなく、むしろデメリットの方が多い？ (van Sonderen et al., 2013)
- 構造方程式モデリングであれば、逆転項目の影響を取り除くことが可能 (Eid, 2000)



日道他 (2017) ※各測定項目についている誤差因子は省略

# 確証の因子分析

```
model5 <- '  
  PD=~Q1S6+Q1S10+Q1S17+Q1S24+Q1S27+Q1S13_v+Q1S19_v  
  EC=~Q1S2+Q1S9+Q1S20+Q1S22+Q1S4_v+Q1S14_v+Q1S18_v  
  PT=~Q1S8+Q1S11+Q1S21+Q1S25+Q1S28+Q1S3_v+Q1S15_v  
  FS=~Q1S1+Q1S5+Q1S16+Q1S23+Q1S26+Q1S7_v+Q1S12_v  
  Rev=~Q1S13_v+Q1S19_v+Q1S4_v+Q1S14_v+Q1S18_v+Q1S3_v+Q1S15_v+  
  Q1S7_v+Q1S12_v  
  PD~~0*Rev ###PDとRevは無相関###  
  EC~~0*Rev  ###ECとRevは無相関###  
  PT~~0*Rev  ###PTとRevは無相関###  
  FS~~0*Rev  ###FSとRevは無相関###  
'
```

```
cfares2 <- cfa(model5, data=dat, orthogonal=F, std.lv=F, estimator="ML",  
  missing="ml")  
summary(cfares2, fit.measures=T, standardized=T)
```

# 分析してみる

- 適合度は改善(CFI=.856, RMSEA=0.060)

- 未だやや低いものの、前の研究(日道他, 2017)と同等の結果
- 同一尺度を用いた海外の研究結果(こちらはオリジナルの4因子モデル)と同等の結果(e.g. de Corte et al., 2007)

```
lavaan 0.6-5 ended normally after 44 iterations

Estimator ML
Optimization method NLMINB
Number of free parameters 99

Number of observations 516
Number of missing patterns 1

Model Test User Model:

Test statistic 950.259
Degrees of freedom 335
P-value (Chi-square) 0.000

Model Test Baseline Model:

Test statistic 4654.570
Degrees of freedom 378
P-value 0.000

User Model versus Baseline Model:

Comparative Fit Index (CFI) 0.856
Tucker-Lewis Index (TLI) 0.838

Loglikelihood and Information Criteria:

Loglikelihood user model (H0) -18088.165
Loglikelihood unrestricted model (H1) -17613.035

Akaike (AIC) 36374.330
Bayesian (BIC) 36794.695
Sample-size adjusted Bayesian (BIC) 36480.450

Root Mean Square Error of Approximation:

RMSEA 0.060
90 Percent confidence interval - lower 0.055
90 Percent confidence interval - upper 0.064
P-value RMSEA <= 0.05 0.000

Standardized Root Mean Square Residual:

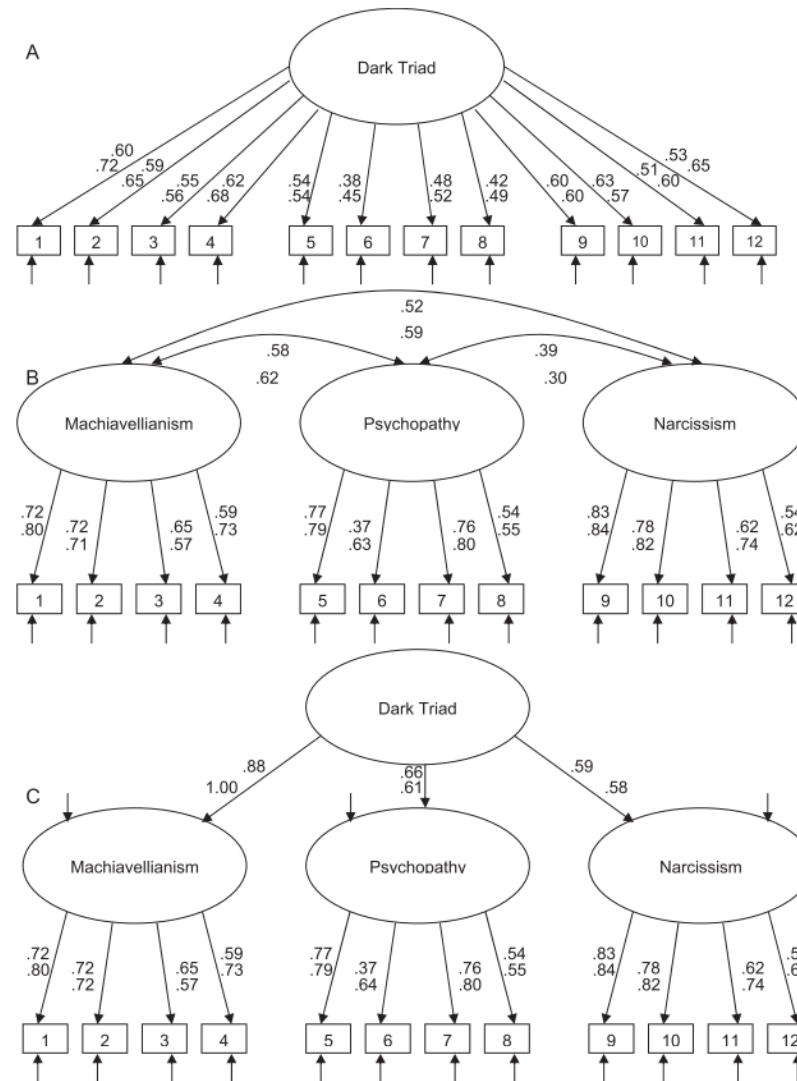
SRMR 0.094

Parameter Estimates:

Information Observed
Observed information based on Hessian
Standard errors Standard
```

# 様々な構造方程式モデリング

- モデル比較が可能

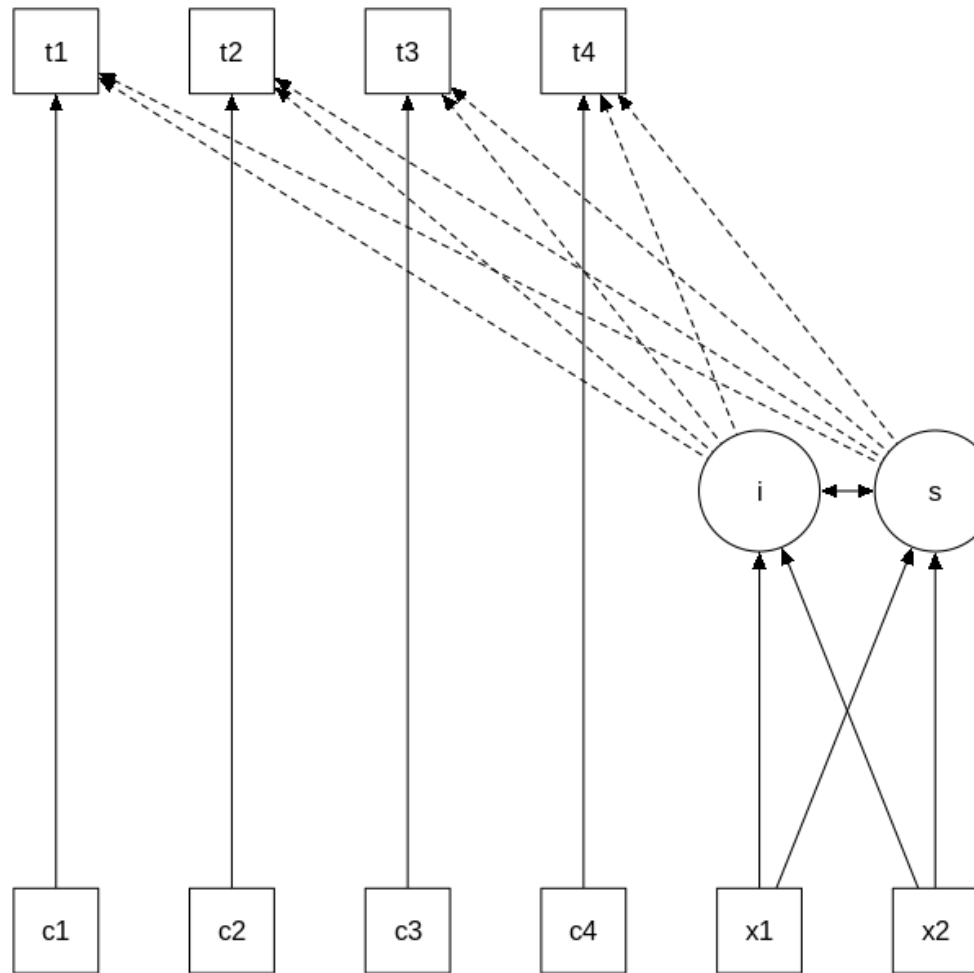


Jonason &  
Webster, 2010

# 様々な構造方程式モデリング

- 潜在曲線モデル

- 傾きと切片の個人差を推定可能

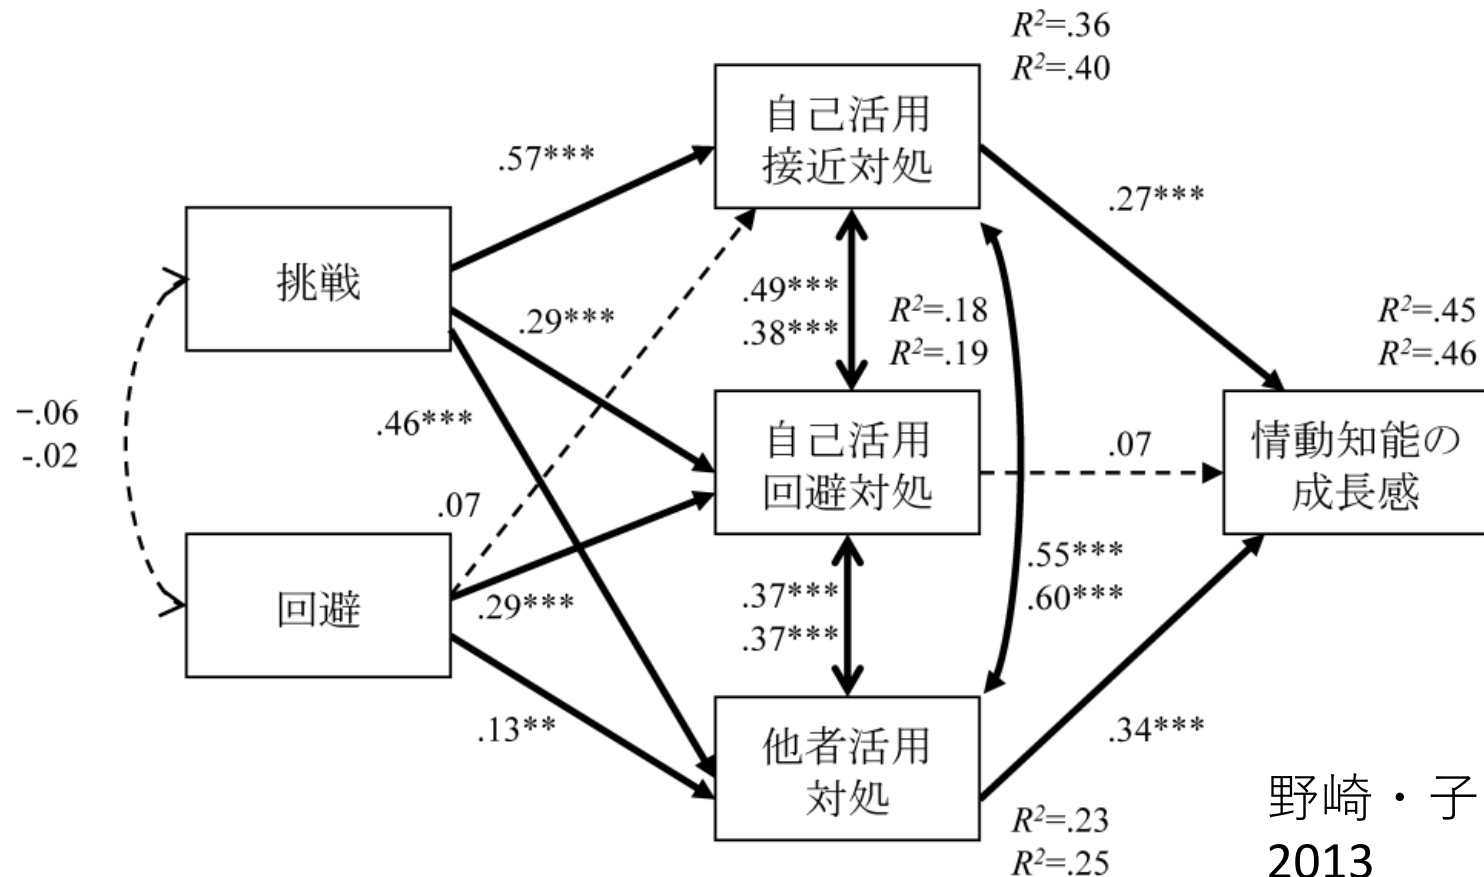


Rosseel Y (2019)

# 様々な構造方程式モデリング

- 他母集団同時分析

- あるグループ間でパス係数や誤差分散, 共分散が等しいかどうか検討





# 参考となるHP・書籍・論文

1. lavaan projectのwebページ(<http://lavaan.ugent.be/index.html>)
2. 小杉考司・清水裕士 (2014) M-plusとRによる構造方程式モデリング 北大路書房
3. 村山 航 (2009) 媒介分析・マルチレベル媒介分析 (<https://koumurayama.com/koujapanese/mediation.pdf>)
4. 狩野裕 (2002) 構造方程式は，因子分析，分散分析，パス解析のすべてにとって代わるのか？ *行動計量学*, 29, 138-159.



# 引用文献

1. de Corte, K., Buysse, A., Verhofstadt, L. L., Roeyers, H., Ponnet, K., & Davis, M. H. (2007). Measuring empathic tendencies: Reliability and validity of the Dutch version of the Interpersonal Reactivity Index. *Psychologica Belgica*, 47, 235–260. doi:10.5334/pb-47-4-235
2. Eid, M. (2000). A multitrait-multimethod model with minimal assumptions. *Psychometrika*, 65, 241–261. doi:10.1007/BF02294377
3. Jonason, P. K., & Webster, G. D. (2010). The dirty dozen: A concise measure of the dark triad. *Psychological assessment*, 22, 420. doi:10.1037/a0019265
4. 狩野裕 (2002) 構造方程式は、因子分析、分散分析、パス解析のすべてにとって代わるのか？ *行動計量学*, 29, 138–159. doi:10.2333/jbhmk.29.138
5. 野崎優樹, & 子安増生. (2013). 大学入試に対する認知的評価とストレス対処が情動知能の成長感に及ぼす効果. *パーソナリティ研究*, 21, 231–243. doi:10.2132/personality.21.231
6. 南風原朝和. (2002). モデル適合度の目標適合度. *行動計量学*, 29, 160–166. doi:10.2333/jbhmk.29.160
7. 日道俊之・小山内秀和・後藤崇志・藤田弥世・河村悠太・Davis, Mark H.・野村理朗 (2017). 日本語版対人反応性指標の作成 *心理学研究*, 88, 61–71. doi:10.4992/jjpsy.88.15218
8. 村山 航 (2009) 媒介分析・マルチレベル媒介分析 <https://koumurayama.com/koujapanese/mediation.pdf>
9. Rosseel Y (2012). “lavaan: An R Package for Structural Equation Modeling.” *Journal of Statistical Software*, 48, 1–36. <http://www.jstatsoft.org/v48/i02/>.
10. Rosseel Y (2019). Growth curves [web blog post] <http://lavaan.ugent.be/tutorial/growth.html>
11. 清水裕士 (2014). 媒介分析 小杉考司・清水裕士(編) M-plusとRによる構造方程式モデリング入門 北大路書房
12. Sonderen Ev, Sanderman R, Coyne JC (2013) Ineffectiveness of Reverse Wording of Questionnaire Items: Let’s Learn from Cows in the Rain. *PLoS ONE* 8(7): e68967. doi:10.1371/journal.pone.0068967